

Módulo: Fundamentos de Análisis de Datos

Programa académico

MSc. Alvaro Chirino Gutierrez

Agosto, 2020⁶

1 Características

- **Programa:** Maestría en Inteligencia Artificial y Gestión de Datos para Finanzas, Economía y Negocios
- **Institución:** Universidad Católica Boliviana (UCB)
- **Docente:** MSc. Alvaro Chirino Gutiérrez
- **Modalidad / Sesiones:** 24 sesiones de 2.5 horas (Lunes, Miércoles y Viernes)
 - Lunes y miércoles de 20:15 a 22:45
 - Viernes de 19:00 a 21:30
- **Estructura de la Sesión:** 150 minutos repartidos en 90 (clase) + 15 (receso) + 45 (clase)
- **Tecnología y Herramientas:** R, RStudio y GitHub

2 Descripción

En este módulo se desarrolla la capacidad para recolectar, depurar, explorar y transformar datos con fines analíticos. Se revisan técnicas de adquisición y manipulación de información, análisis exploratorio, tratamiento de datos faltantes, estrategias avanzadas de data wrangling (incluyendo expresiones regulares, web scraping y programación funcional) y procesos de ingeniería de características. Se busca que el estudiante domine las etapas iniciales y fundamentales del ciclo de vida del análisis de datos, garantizando su calidad, validez y utilidad para su posterior análisis o visualización interactiva.

3 Propósito

Proporcionar a los estudiantes los conocimientos y habilidades esenciales para recolectar, limpiar, explorar, analizar e interpretar datos en diversos contextos, estableciendo una base sólida para el desarrollo de productos de datos y dashboards.

4 Unidades de Aprendizaje

- **Unidad 1: Adquisición, Transformación y Manipulación de Datos**
 - Configuración del entorno (R/RStudio, GitHub).
 - Adquisición de datos: archivos planos, bases de datos, consumo de APIs (JSON/XML) y Web Scraping.
 - Principios de “Tidy Data” y reestructuración de conjuntos de datos.

- Manejo avanzado de tipos de datos: Expresiones regulares (regex) para texto y manipulación de fechas/horas.
- **Unidad 2: Análisis Exploratorio y Tratamiento de Datos Faltantes**
 - **Análisis Exploratorio de Datos (EDA):** Visualizaciones, estadística descriptiva y análisis preliminares.
 - **Tratamiento de Datos Faltantes:** Mecanismos de pérdida, diagnóstico y técnicas de imputación.
- **Unidad 3: Data Wrangling Avanzado, Big Data y Datos Desequilibrados**
 - **Data Wrangling:** Programación funcional aplicada a la limpieza (listas y dataframes), cruces relacionales y optimización.
 - **Ingeniería de Características:** Creación, transformación y selección de atributos.
 - **Datos Desequilibrados:** Tratamiento analítico, técnicas de remuestreo y balanceo de clases.

5 Sistema de Evaluación (100 Puntos)

- **Laboratorio 1 (30 puntos):** Ejercicios prácticos de adquisición (incluyendo scraping/APIs), manipulación de datos (Tidy Data, regex) y Análisis Exploratorio (EDA).
- **Laboratorio 2 (30 puntos):** Práctica avanzada de tratamiento de datos faltantes, Data Wrangling (programación funcional), ingeniería de características y balanceo de datos.
- **Trabajo Práctico Final (40 puntos):** Desarrollo e implementación de un **Dashboard en R** para el seguimiento interactivo de métricas.
 - *Requisitos:* El dashboard debe calcular e ilustrar **KPIs**, utilizar estrictamente un **dataset nacional** y enfocarse en un área temática **diferente al área de dominio** del estudiante.

6 Cronograma Semanal (8 Semanas / 24 Sesiones)

Nota: Todas las sesiones (2.5 horas) cuentan con una pausa de 15 minutos tras los primeros 90 minutos de clase.

Semana 1: Entorno y Adquisición de Datos Estructurados y No Estructurados

- **Sesión 1 (Lunes):** Presentación del módulo, **Clase Inicial con Evaluación Diagnóstica** y configuración del entorno (R, RStudio, GitHub).
- **Sesión 2 (Miércoles):** Estrategias de adquisición de datos (archivos flat, bases de datos relacionales, importación de JSON/XML).
- **Sesión 3 (Viernes):** Consumo de datos mediante APIs y técnicas de Web Scraping (rvest).

Semana 2: Transformación, Tidy Data y Manipulación Específica

- **Sesión 4 (Lunes):** Estructuras de datos en R, manipulación básica y filosofía “Tidy Data”.
- **Sesión 5 (Miércoles):** Transformación y reestructuración avanzada de datos (dplyr, tidyr - pivot_longer/pivot_wider).
- **Sesión 6 (Viernes):** Operaciones específicas: Expresiones regulares (regex) para cadenas de texto (stringr) y manejo de fechas (lubridate).

Semana 3: Análisis Exploratorio de Datos (EDA) y Evaluación 1

- **Sesión 7 (Lunes):** Estadística descriptiva y medidas de resumen.

- **Sesión 8 (Miércoles):** Visualización de datos y análisis preliminares (ggplot2).
- **Sesión 9 (Viernes): Evaluación: Laboratorio 1 (30 puntos).**

Semana 4: Tratamiento de Datos Faltantes

- **Sesión 10 (Lunes):** Identificación y diagnóstico de datos faltantes (MCAR, MAR, MNAR).
- **Sesión 11 (Miércoles):** Métodos de imputación simple.
- **Sesión 12 (Viernes):** Métodos de imputación múltiple y evaluación de impacto.

Semana 5: Data Wrangling Avanzado y Programación Funcional

- **Sesión 13 (Lunes):** Programación funcional aplicada al Data Wrangling (purrr) e iteración sobre estructuras complejas (listas).
- **Sesión 14 (Miércoles):** Cruces espaciales y relacionales complejos (Joins).
- **Sesión 15 (Viernes):** Optimización en la preparación de bases de datos para Big Data.

Semana 6: Ingeniería de Características y Datos Desequilibrados

- **Sesión 16 (Lunes):** Ingeniería de características: escalado, codificación y creación de variables predictivas.
- **Sesión 17 (Miércoles):** Problemática y diagnóstico de datos desequilibrados.
- **Sesión 18 (Viernes): Evaluación: Laboratorio 2 (30 puntos)** (Tratamiento de faltantes, wrangling y balanceo).

Semana 7: Desarrollo de Dashboards en R

- **Sesión 19 (Lunes):** Introducción al desarrollo de Dashboards en R (Shiny / flexdashboard) y control de versiones en GitHub.
- **Sesión 20 (Miércoles):** Construcción y diseño de KPIs efectivos.
- **Sesión 21 (Viernes):** Taller práctico: Exploración y selección de Datasets Nacionales.

Semana 8: Proyecto Final y Defensa

- **Sesión 22 (Lunes):** Mentoría y revisión de avances del Trabajo Práctico (verificación de área fuera de dominio).
- **Sesión 23 (Miércoles):** Ajustes finales, pruebas de usabilidad y despliegue del dashboard.
- **Sesión 24 (Viernes): Clase Final: Defensa del Trabajo Práctico (40 puntos).**

7 Referencias Bibliográficas

1. Wickham, H., Golemund, G., & Çetinkaya-Rundel, M. (2023). *R for Data Science* (2nd ed.). O'Reilly Media.
Disponible gratuitamente en: <https://r4ds.hadley.nz/>
2. Boehmke, B. (2016). *Data Wrangling with R*. Springer.
(Referencia fundamental para expresiones regulares, manejo de strings, fechas, listas y web scraping en R)
3. Kuhn, M., & Johnson, K. (2019). *Feature Engineering and Selection: A Practical Approach for Predictive Models*. CRC Press.
Disponible gratuitamente en: <https://bookdown.org/max/FES/>
4. Lovelace, R., Nowosad, J., & Muenchow, J. (2019). *Geocomputation with R*. CRC Press.
Disponible gratuitamente en: <https://geocompr.robinlovelace.net/>